

# Глава 1

## Выбор субоптимальной структуры модели

В данной главе рассматривается задача выбора структуры модели глубокого обучения. Предлагается ввести вероятностные предположения о распределениях параметров и структуры модели. Проводится градиентная оптимизация параметров и гиперпараметров модели на основе байесовского вариационного вывода. В качестве оптимизируемой функции для гиперпараметров модели предлагается обобщенная функция обоснованности. Показано, что данная функция позволяет проводить оптимизацию, соответствующую нескольким критериям выбора структуры модели: методу максимального правдоподобия, последовательному увеличению и снижению сложности модели, полному перебору структуры модели, а также получению максимума вариационной оценки обоснованности модели. Решается двухуровневая задача оптимизации: на первом уровне проводится оптимизация нижней оценки обоснованности модели по вариационным параметрам модели. На втором уровне проводится оптимизация гиперпараметров модели.

### 1.1. Вероятностная модель

Определим априорные распределения параметров и структуры модели следующим образом. Пусть параметры модели распределены нормально с нулевым средним:

$$\mathbf{w}_k^{i,j} \sim \mathcal{N}(\mathbf{0}, \gamma_k^{i,j} (\mathbf{A}_k^{i,j})^{-1}),$$

где  $(\mathbf{A}_k^{i,j})^{-1}$  — диагональная матрица. Априорное распределение  $p(\mathbf{w}|\mathbf{\Gamma}, \mathbf{h})$  параметров  $\mathbf{w}_k^{i,j}$  зависит не только от гиперпараметров  $\mathbf{A}_k^{i,j}$ , но и от структурного параметра  $\gamma_k^{i,j}$ .

В качестве априорного распределения для структуры  $\mathbf{\Gamma}$  предлагается использовать произведение распределение Gumbel-Softmax [?]:

$$p(\mathbf{\Gamma}|\mathbf{h}, \boldsymbol{\lambda}) = \prod_{(j,k) \in E} p(\gamma^{j,k}|\mathbf{s}, \lambda_{\text{temp}}),$$

где для каждого структурного параметра  $\gamma$  с количеством базовых функций  $K$  вероятность  $p(\gamma|\mathbf{s}, \lambda_{\text{temp}})$  определена следующим образом:

$$p(\gamma|\mathbf{s}, \lambda_{\text{temp}}) = (K-1)! \lambda_{\text{temp}}^{K-1} \prod_{p=1}^K s_p \gamma_p^{-\lambda_{\text{temp}}-1} \left( \sum_{p=1}^K s_p \gamma_p^{-\lambda_{\text{temp}}} \right)^{-K},$$

где  $\mathbf{s} \in (0, \infty)^K$  — гиперпараметр, отвечающий за смещенность плотности распределения относительно точек симплекса на  $K$  вершинах,  $\lambda_{\text{temp}}$  — метапараметр температуры, отвечающий за концентрацию плотности вблизи вершин симплекса или в центре симплекса.

- Перечислим свойства, которыми обладает распределение Gumbel-Softmax:
1. Реализацию  $\hat{\gamma}_p$ , т.е.  $p$ -й компоненты случайной величины  $\gamma$  можно породить следующим образом:

$$\hat{\gamma}_p = \frac{\exp(\log s_p + \hat{g}_p)/\lambda_{\text{temp}}}{\sum_{p'=1}^K \exp(\log s_{p'} + \hat{g}_{p'})/\lambda_{\text{temp}}},$$

где  $\hat{\mathbf{g}} \sim -\log(-\log \mathcal{U}(0, 1)^K)$ .

2. Свойство округления:  $p(\gamma_{p_1} > \gamma_{p_2}, p_1 \neq p_2) = \frac{s_{p_1}}{\sum_{p'} s_{p'}}$ .
3. При устремлении температуры к нулю реализация случайной величины концентрируется на вершинах симплекса:

$$p(\lim_{\lambda_{\text{temp}} \rightarrow 0} \gamma_p = 1) = \frac{s_p}{\sum_{p'} s_{p'}}.$$

4. При устремлении температуры к бесконечности плотность распределения концентрируется в центре симплекса:

$$\lim_{\lambda_{\text{temp}} \rightarrow \infty} p(\gamma | \mathbf{h}) = \begin{cases} \infty, \gamma_p = \frac{1}{K}, p \in \{1, \dots, K\}, \\ 0, \text{ иначе.} \end{cases} \quad (1.1)$$

Доказательства первых трех утверждений приведены в [?]. Докажем утверждение 4.

*Доказательство.* Формула плотности записывается следующим образом с точностью до множителя:

$$\frac{\lambda_{\text{temp}}^{K-1}}{\left( \sum_{p=1}^K s_p \gamma_p^{-\frac{K-1}{K} \lambda_{\text{temp}}} \sum_{p'=1}^K [p \neq p'] s_{p'} \gamma_{p'}^{-\frac{1}{K} \lambda_{\text{temp}}} \right)^K}$$

Заметим, что числитель  $\lambda_{\text{temp}}^{K-1}$  имеет меньшую скорость сходимости, чем знаменатель. Знаменатель является суммой слагаемых вида:

$$\left( \frac{\prod_{p' \neq p} \gamma_{p'}^{\frac{1}{K}}}{\gamma_p^{\frac{K-1}{K}}} \right)^{\lambda_{\text{temp}}}. \quad (1.2)$$

Пусть хотя бы для одного  $p$ :  $\gamma_p \neq \frac{1}{K}$ . Пусть  $p'$  соответствует индексу максимальной компоненты вектора  $\gamma$ . Для  $p = p'$  предел выражения (1.2) при  $\lambda_{\text{temp}}$  стремится к бесконечности. Для  $p \neq p'$  предел выражения (1.2) при  $\lambda_{\text{temp}}$  стремится к нулю. Возводя сумму пределов в степень  $-K$  получаем предел плотности, равный нулю.

Пусть  $\gamma = \frac{1}{K}$ . Тогда выражение с точностью до множителя упрощается до  $\lambda^{K-1}$ . Предел данного выражения стремится к бесконечности. Таким образом, предел плотности Gumbel-Softmax равен выражению (1.1), что и требовалось доказать.

□




Рис. 1.1. Пример распределения Gumbel-Softmax при различных значениях параметров: а)  $\lambda_{temp} \rightarrow 0$ , б)  $\lambda_{temp} = 1, \mathbf{s} = [1, 1, 1]$ , в)  $\lambda_{temp} = 5, \mathbf{s} = [1, 1, 1]$ , г)  $\lambda_{temp} = 5, \mathbf{s} = [10, 0.1, 0.1]$ .

Первое свойство Gumbel-Softmax распределения позволяет использовать репараметризацию при вычислении градиента в вариационном выводе (англ. reparametrization trick). Данный подход позволяет значительно повысить точность вычисления градиента от функций, зависящих от случайных величин [?]. Пример распределения Gumbel-Softmax при различных параметрах представлен на Рис. 1.1. В качестве альтернативы для априорного распределения на структуре выступает распределение Дирихле и равномерное распределение. Выбор в качестве распределения на структуре произведения Gumbel-Softmax распределения обоснован выбором этого же распределения в качестве вариационного. TODO: подробнее.

Заметим, что предлагаемое априорное распределение неоднозначно: одно и то же распределение можно получить с различными значениями гиперпараметра  $\mathbf{A}_k^{i,j}$  и структурного параметра  $\gamma_k^{i,j}$ . В качестве регуляризатора для матрицы  $(\mathbf{A}_k^{i,j})^{-1}$  предлагается использовать обратное гамма-распределение:

$$(\mathbf{A}_k^{i,j})^{-1} \sim \text{inv-gamma}(\lambda_1, \lambda_2),$$

где  $\lambda_1, \lambda_2 \in \boldsymbol{\lambda}$  — метапараметры оптимизации. Использование обратного гамма-распределения в качестве распределения гиперпараметров можно найти в [?, ?]. В данной работе обратное распределение выступает как регуляризатор гиперпараметров. Калибруя метапарамы  $\lambda_1, \lambda_2$  можно получить более сильную или более слабую регуляризацию [?]. Пример распределений  $\text{inv-gamma}(\lambda_1, \lambda_2)$  для разных значений метапараметров  $\lambda_1, \lambda_2$  изображен на Рис. 1.2.

Таким образом, предлагаемая вероятностная модель содержит следующие компоненты:

1. Параметры  $\mathbf{w}$  модели, распределенные нормально.
2. Структура модели  $\boldsymbol{\Gamma}$  распределены по распределению Gumbel-Softmax.
3. Гиперпараметры:  $\mathbf{h} = [\text{diag}(\mathbf{A}), \mathbf{s}]$ , где  $\mathbf{A}$  — конкатенация матриц  $\mathbf{A}^{j,k}, (j, k) \in E$ ,  $\mathbf{s}$  — конкатенация параметров Gumbel-Softmax распределений  $\mathbf{s}^{j,k}, (j, k) \in E$ , где  $E$  — множество ребер, соответствующих графу рассматриваемого параметрического семейства.
4. Метапараметры:  $\boldsymbol{\lambda} = [\lambda_1, \lambda_2]$ .




Рис. 1.2. Графики обратных гамма распределений для различных значений метапараметров.

График вероятностной модели в формате плоских нотаций представлен на Рис. 1.3.

## 1.2. Вариационная оценка для обоснованности вероятностной модели

В качестве критерия выбора структуры модели предлагается использовать апостериорную вероятность гиперпараметров:

$$p(\mathbf{h}|\mathbf{y}, \mathbf{X}, \boldsymbol{\lambda}) \propto p(\mathbf{y}|\mathbf{X}, \mathbf{h}, \boldsymbol{\lambda})p(\mathbf{h}|\boldsymbol{\lambda}) \rightarrow \max_{\mathbf{h} \in \mathbb{H}}, \quad (1.3)$$




Рис. 1.3. График предлагаемой вероятностной модели в формате плоских нотаций. Переменные обозначены белыми и серыми кругами, константы обозначены обведенными черными кругами. Наблюдаемые переменные обозначены серыми кругами.

где структура модели и параметры модели выбираются на основе полученных значений гиперпараметров:

$$\Gamma^* = \arg \max_{\Gamma \in \mathbb{T}} p(\Gamma | \mathbf{y}, \mathbf{X}, \mathbf{h}^*),$$

$$\mathbf{w}^* = \arg \max_{\mathbf{w} \in \mathbb{W}} p(\mathbf{w} | \mathbf{y}, \mathbf{X}, \Gamma^*, \mathbf{h}^*),$$

где  $\mathbf{h}^*$  — решение задачи оптимизации (1.3).

Для вычисления обоснованности

$$p(\mathbf{y} | \mathbf{X}, \mathbf{h}, \lambda) = \iint_{\Gamma, \mathbf{w}} p(\mathbf{y} | \mathbf{X}, \mathbf{w}, \Gamma, \lambda) p(\mathbf{w} | \Gamma, \mathbf{h}, \lambda) p(\Gamma | \mathbf{h}, \lambda)$$

из (1.3) предлагается использовать вариационную оценку обоснованности.

**Теорема 1.** Пусть  $q = q_{\mathbf{w}} q_{\Gamma}$  — вариационное распределение с параметрами  $\theta$ , аппроксимирующее апостериорное распределение структуры и параметров:

$$q(\mathbf{w}, \Gamma | \theta) \approx p(\mathbf{w}, \Gamma | \mathbf{y}, \mathbf{X}, \mathbf{h}, \lambda),$$

$$q_{\mathbf{w}}(\mathbf{w} | \theta_{\mathbf{w}}, \Gamma) \approx p(\mathbf{w} | \mathbf{y}, \mathbf{X}, \Gamma, \mathbf{h}, \lambda),$$

$$q_{\Gamma}(\Gamma | \theta_{\Gamma}) \approx p(\Gamma | \mathbf{y}, \mathbf{X}, \mathbf{h}, \lambda).$$

Тогда справедлива следующая оценка:

$$\log p(\mathbf{y} | \mathbf{X}, \mathbf{h}, \lambda) \geq \quad (1.4)$$

$$\mathbb{E}_{\Gamma \sim q_{\Gamma}} \mathbb{E}_{\mathbf{w} \sim q_{\mathbf{w}}} \log p(\mathbf{y} | \mathbf{w}, \Gamma, \mathbf{X}) - D_{\text{KL}}(q_{\Gamma}(\Gamma | \theta_{\Gamma}) | p(\Gamma | \mathbf{h}, \lambda)) - D_{\text{KL}}(q_{\mathbf{w}}(\mathbf{w} | \theta_{\mathbf{w}}, \Gamma) | p(\mathbf{w} | \Gamma, \mathbf{h})),$$

где  $D_{\text{KL}}(q_{\mathbf{w}}(\mathbf{w} | \theta_{\mathbf{w}}, \Gamma) | p(\mathbf{w} | \Gamma, \mathbf{h}))$  вычисляется по формуле условной дивергенции [?]:

$$D_{\text{KL}}(q_{\mathbf{w}}(\mathbf{w} | \theta_{\mathbf{w}}, \Gamma) | p(\mathbf{w} | \Gamma, \mathbf{h})) = \mathbb{E}_{\Gamma \sim q_{\Gamma}} \mathbb{E}_{\mathbf{w} \sim q_{\mathbf{w}}} \frac{\log q(\mathbf{w} | \Gamma)}{\log p(\mathbf{w} | \mathbf{h}, \Gamma)}.$$

*Доказательство.* Используя неравенство Йенсена получим

$$\log p(\mathbf{y} | \mathbf{X}, \mathbf{h}, \lambda) \geq$$

$$\mathbb{E}_q \log p(\mathbf{y} | \mathbf{w}, \Gamma, \mathbf{X}) - D_{\text{KL}}(q(\mathbf{w}, \Gamma | \theta) | p(\mathbf{w}, \Gamma | \mathbf{h})).$$

Декомпозируем распределение  $q$  по свойству условной дивергенции:

$$D_{\text{KL}}(q(\mathbf{w}, \Gamma | \theta) | p(\mathbf{w}, \Gamma | \mathbf{h})) = D_{\text{KL}}(q_{\Gamma}(\Gamma | \theta_{\Gamma}) | p(\Gamma | \mathbf{h}, \lambda)) - D_{\text{KL}}(q_{\mathbf{w}}(\mathbf{w} | \theta_{\mathbf{w}}, \Gamma) | p(\mathbf{w} | \Gamma, \mathbf{h})).$$

□




Рис. 1.4. График предлагаемой вероятностной вариационной модели в формате плоских нотаций. Переменные обозначены белыми и серыми кругами, константы обозначены обведенными черными кругами. Вариационное распределение обозначено черным кругом. Наблюдаемые переменные обозначены серыми кругами.

В качестве вариационного распределения  $q_{\mathbf{W}}$  предлагается использовать нормальное распределение, не зависящее от структуры модели  $\mathbf{\Gamma}$ :

$$q_{\mathbf{W}} = \mathcal{N}(\boldsymbol{\mu}, \mathbf{A}_q),$$

где  $\mathbf{A}_q$  — диагональная матрица с диагональю  $\boldsymbol{\alpha}_q$ .

В качестве вариационного распределения  $q_{\mathbf{\Gamma}}$  предлагается использовать произведение распределений Gumbel-Softmax. конкатенацию параметров концентрации распределений обозначим как  $\mathbf{s}_q$ . Температуру вариационного распределения на структуре  $\mathbf{\Gamma}$  обозначим как  $\theta_{\text{temp}}$ .

Вариационными параметрами распределения  $q$  являются параметры распределений  $q_{\mathbf{W}}, q_{\mathbf{\Gamma}}$ :

$$\boldsymbol{\theta} = [\boldsymbol{\mu}, \boldsymbol{\sigma}_q^2, \mathbf{s}_q, \theta_{\text{temp}}],$$

где  $\mathbf{s}_q, \theta_{\text{temp}}$  — параметры Gumbel-Softmax распределений.

График вероятностной вариационной модели в формате плоских нотаций представлен на Рис. 1.4.

Для вычисления приближенного значения вариационной оценки обоснованности (1.4) предлагается использовать следующую формулу:

$$\begin{aligned} & \sum_{r=1}^R \log p(\mathbf{y} | \boldsymbol{\mu} + \boldsymbol{\alpha}_q \circ \hat{\epsilon}_r, \hat{\mathbf{\Gamma}}_r, \mathbf{X}) - \sum_{r=1}^R \left( \log q_{\mathbf{\Gamma}}(\hat{\mathbf{\Gamma}}_r | \boldsymbol{\theta}_{\mathbf{\Gamma}}) - p(\hat{\mathbf{\Gamma}} | \mathbf{h}, \boldsymbol{\lambda}) \right) - \\ & - \sum_{r=1}^R \frac{1}{2} \left( \hat{\mathbf{\Gamma}}_r^{-1} \text{tr}(\mathbf{A}_q \mathbf{A}^{-1}) + \boldsymbol{\mu}^T \hat{\mathbf{\Gamma}}_r^{-1} \mathbf{A}^{-1} \boldsymbol{\mu} - |\mathbf{W}| + \log \frac{|\mathbf{\Gamma}_r \mathbf{A}|}{|\mathbf{A})_q|} \right), \end{aligned}$$

где  $r$  — множество реализаций случайных величин, по котором вычисляется значения вариационной оценки обоснованности,  $\hat{\epsilon}_r \sim \mathcal{N}(0, 1)$ ,  $\hat{\Gamma}_r$  — реализация случайной величины, соответствующей структуре  $\Gamma$ .

Для анализа сложности полученной модели введем понятие *параметрической сложности*.

**Определение 1.** Параметрической сложностью  $C_p(\theta)$  модели с вариационными параметрами  $\theta$  назовем минимальную дивергенцию между вариационным и априорным распределением:

$$C_p(\theta) = \min_{\mathbf{h} \in \mathbb{H}} D_{\text{KL}}(q(\mathbf{w}, \Gamma | \theta) | p(\mathbf{w}, \Gamma | \mathbf{h})).$$

Параметрическая сложность модели соответствует ожидаемой длине описания параметров модели при условии заданного параметрического априорного распределения [?].

Одним из критериев удаления неинформативных параметров в вероятностных моделях является вариационная плотность [?]: отношение вариационной плотности параметров в моде распределения к вариационной плотности параметра в нуле:

$$\frac{q_{\mathbf{w}}(\mu | \theta_{\mathbf{w}})}{q(0)} = \exp\left(-\frac{2\alpha_q^2}{\mu^2}\right),$$

где  $q_{\mathbf{w}}(w | \theta_{\mathbf{w}}) \sim \mathcal{N}(\mu, \alpha_q)$ .

Обобщим понятие относительной вариационной плотности на случай произвольных распределений.

**Определение 2.** Относительной вариационной параметра плотностью  $w \in \mathbf{w}$  при условии структуры  $\Gamma$  и гиперпараметров  $\mathbf{h}$  назовем отношение моды вариационного распределения параметра к моде априорного распределению параметра:

$$\rho(w | \Gamma, \theta_{\mathbf{w}}, \mathbf{h}, \lambda) = \frac{q(\text{mode } q(w | \Gamma, \theta_{\mathbf{w}}) | \Gamma \theta_{\mathbf{w}})}{q(\text{mode } p(w | \Gamma, \mathbf{h}, \lambda) | \Gamma \theta_{\mathbf{w}})},$$

$$\rho(\mathbf{w} | \Gamma, \theta_{\mathbf{w}}, \mathbf{h}, \lambda) = \prod_{w \in \mathbf{w}} \rho(w | \Gamma, \theta_{\mathbf{w}}, \mathbf{h}, \lambda).$$

Сформулируем и докажем теорему о связи относительной плотности и параметрической сложности модели:

**Теорема 2.** Пусть вариационное распределение  $q_{\mathbf{w}}$  и априорное распределение  $p(w | \Gamma, \mathbf{h})$  являются унимодальными со свойством:

$$\text{mode } q_{\mathbf{w}} = \mathbb{E}_{q_{\mathbf{w}}} w, \quad \text{mode } p(w | \Gamma, \mathbf{h}) = \mathbb{E}_p(w | \Gamma, \mathbf{h}) \quad w.$$

Пусть  $\theta_1, \theta_2, \dots$  — бесконечная последовательность векторов вариационных параметров, такая что  $\lim_{i \rightarrow \infty} C_p(\theta_i) = 0$ ,  $\lim \sigma_q \neq 0$ ,  $\lim \theta_q \neq 0$ . С вариационной

вероятностью  $q_{\Gamma}$  вариационная плотность данной последовательности стремится к единице:

$$\lim_{i \rightarrow \infty} \int_{\Gamma} \rho(\mathbf{w}|\Gamma, \mathbf{h}_i) q(\Gamma) d\Gamma = 1,$$

где  $\mathbf{h}_i = \arg \min_{\mathbf{h} \in \mathbb{H}} D_{\text{KL}}(q(\mathbf{w}, \Gamma|\boldsymbol{\theta})|p(\mathbf{w}, \Gamma|\mathbf{h}))$ . Пусть мода априорного распределения не зависит от гиперпараметров.

*Доказательство.* Предел параметрической сложности перепишем как

$$D_{\text{KL}}(q_{\mathbf{w}}|p|\gamma) + D_{\text{KL}}(q_{\gamma}|p).$$

Т.к. параметрическая сложность состоит из двух неотрицательных слагаемых, то в пределе оба слагаемых достигают нуля. Рассмотрим первое слагаемое:

$$D_{\text{KL}}(q_{\mathbf{w}}|p|\gamma) = \mathbb{E}_q D_{\text{KL}}(q_{\mathbf{w}}|p|\gamma).$$

Отсюда и используя свойство теоремы о монотонной сходимости:

$$0 = \lim D_{\text{KL}}(q_{\mathbf{w}}|p|\gamma) = \mathbb{E} \lim D_{\text{KL}}(q_{\mathbf{w}}|p|\gamma).$$

Поэтому для измеримого множества единичной меры дивергенция между априорным распределением и вариационным будет нулевой. Рассмотрим разность предел разности мод двух распределений при  $\Gamma$ :

$$\lim(\text{mode } q - \text{mode } p) = \lim \mathbb{E}_q \mathbf{w} - \mathbb{E}_p \mathbf{w} = \lim \int_{\mathbf{w}} \mathbf{w}(p - q) d\mathbf{w}.$$

Т.к.  $(p - q) \rightarrow 0$  почти наверно, то

$$\lim \int_{\mathbf{w}} \mathbf{w}(p - q) d\mathbf{w} = \int_{\mathbf{w}} \lim \mathbf{w}(p - q) d\mathbf{w} = 0.$$

Отсюда разность мод для данных распределений в пределе равняется нулю.

Рассмотрим относительную плотность:

$$\frac{q}{p} = \lim = 1.$$

□

Теорема утверждает, что при устремлении параметрической сложности моделей к нулю, параметры модели становятся неинформативными и подлежащими удалению. Заметим, что последовательность  $q$  не обязана иметь предел. Примером такой последовательности может быть последовательность гауссовых распределений, чье среднее стремится к нулю.



### 1.3. Обобщающая задача

Рассмотрим основные критерии выбора вероятностных моделей.

1. Критерий максимального правдоподобия:

$$\log p(\mathbf{y}|\mathbf{X}, \mathbf{w}) \rightarrow \max_{\mathbf{w} \in \mathbb{W}}.$$

Метод заключается в максимизации правдоподобия обучающей выборки и подвержен переобучению. Для использования данного метода в контексте вариационных распределений предлагается следующее обобщение:

$$L = \mathbb{E}_q \log \log p(\mathbf{y}|\mathbf{X}, \mathbf{w}).$$

Для данного метода нет оптимизируемых гиперпараметров. Для формального соответствия данной задачи задаче выбора положим  $L = Q$ . Заметим, что частным случаем задачи является метод правдоподобия при выборе в качестве  $q$  эмпирического распределения параметров и структуры.

2. Перебор структуры:

$$L = Q = \mathbb{E}_q \log p(\mathbf{y}, \mathbf{w}|\mathbf{X})[q_{\Gamma} = p']$$

где  $p'$  — некоторое распределение на структуре, выступающее в качестве метопараметра.

3. Метод максимальной апостериорной вероятности.

$$\log p(\mathbf{y}, \mathbf{w}|\mathbf{X}, \mathbf{h}) \rightarrow \max_{\mathbf{w} \in \mathbb{W}}.$$

Аналогично предыдущему методу сформулируем вариационное обобщение данной задачи:

$$L = Q = \mathbb{E}_q \log \log p(\mathbf{y}|\mathbf{X}, \mathbf{w}) + \log p(\mathbf{w}|\boldsymbol{\lambda}) + \log p(\boldsymbol{\gamma}|\mathbf{X}, \mathbf{w}).$$

В рамках данной задачи оптимизации параметры априорных распределений  $\mathbf{A}, \mathbf{s}$  выступают в качестве метопараметров, и поэтому не подлежат оптимизации.

4. Метод вариационной оценки обоснованности.

$$L = Q = \mathbb{E}_q \log p(\mathbf{y}|\mathbf{X}, \mathbf{w}) - D_{\text{KL}}(q|p).$$

5. Hold-out кросс-валидация.

$$L = \mathbb{E}_q \log p(\mathbf{y}, \mathbf{w}|\mathbf{X}, \mathbf{h}),$$

$$Q = \mathbb{E}_q \log p(\mathbf{y}|\mathbf{X}, \mathbf{w}).$$

6. Критерий Акаике:

$$\log p(\mathbf{y}|\mathbf{X}, \mathbf{w}) - |\mathbb{W}|.$$

Заметим, что в условия выбора модели на параметрическом множестве моделей данный критерий не имеет смысла, т.к. количество параметров для каждой модели одинаково. Прелагается следующая переформулировка:

$$AIC_\lambda = \log p(\mathbf{y}|\mathbf{X}, \mathbf{w}) - |\{w : C_p(w) < \lambda\}|.$$

7. Информационный критерий Шварца:

$$\log p(\mathbf{y}|\mathbf{X}, \mathbf{w}) - 0.5 \log(m) |\mathbb{W}|.$$

Переформулируем данный критерий аналогично критерию AIC:

$$BIC_\lambda = \log p(\mathbf{y}|\mathbf{X}, \mathbf{w}) - \log(m) |\{w : C_p(w) < \lambda\}|.$$

Каждый из рассмотренных критерии удовлетворяет хотя бы одному из перечисленных свойств:

1. Модель, оптимизируемая согласно критерию, доставляет максимум правдоподобия выборки;
2. Модель, оптимизируемая согласно критерию, доставляет максимум оценки обоснованности;
3. Для моделей, доставляющих сопоставимые значения правдоподобия выборки, выбирается модель с меньшим количеством информативных параметров.
4. Критерий позволяет производить перебор структур для отбора наилучших модели.

Формализуем рассмотренные критерии. Оптимизационную задачу, которая удовлетворяет всем перечисленным свойствам, будет называть *обобщающей*.

**Определение 3.** Двухуровневую задачу оптимизации будем называть *обобщающей* на области  $U \subset \Theta \times \mathbb{H} \times \mathbb{A}$ , если она удовлетворяет следующим свойствам:

1. Для каждого значения гиперпараметров  $\mathbf{h}$  оптимальное решение нижней задачи оптимизации  $\boldsymbol{\theta}^*$  определено однозначно.
2. Свойство максимизации правдоподобия выборки: существует  $\boldsymbol{\lambda} \in U_\lambda$  и  $K_1 \in \mathbb{R}_+$ , такие что для любых векторов гиперпараметров  $\mathbf{h}_1, \mathbf{h}_2 \in U_h$ ,  $Q(\mathbf{h}_1) - Q(\mathbf{h}_2) > K_1$  : матожидания правдоподобия выборок:  $\mathbb{E}_q \log p(\mathbf{y}|\mathbf{X}, \boldsymbol{\theta}_1, \lambda_{\text{temp}}, \mathbf{f}) > \log \mathbb{E}_q p(\mathbf{y}|\mathbf{X}, \boldsymbol{\theta}_2, \lambda_{\text{temp}}, \mathbf{f})$ .
3. Свойство минимизации параметрической сложности: существует  $\boldsymbol{\lambda} \in U_\lambda$  и  $K_2 \in \mathbb{R}_+$ , такие что для любых векторов гиперпараметров  $\mathbf{h}_1, \mathbf{h}_2 \in U_h$ ,  $Q(\mathbf{h}_1) - Q(\mathbf{h}_2) > K_2$ ,  $\mathbb{E}_q \log p(\mathbf{y}|\boldsymbol{\theta}_1, \lambda_{\text{temp}}, \mathbf{f}) = \log \mathbb{E}_q p(\mathbf{y}|\boldsymbol{\theta}_2, \lambda_{\text{temp}}, \mathbf{f})$ , количество ненулевых параметров у первой модели меньше, чем у второй.
4. Свойства приближения оценки обоснованности: существует значение гиперпараметров  $\boldsymbol{\lambda}$ , такое что оптимизация задачи эквивалента оптимизации вариационной оценки обоснованности модели.

5. Свойство перебора структур: существует константа  $K_3$ , такая что для любых двух векторов  $\mathbf{h}_1, \mathbf{h}_2$  и соответствующих векторов  $\boldsymbol{\theta}_1^*, \boldsymbol{\theta}_2^* : D_{\text{KL}}(q_{\Gamma_2}, q_{\Gamma_1}) > K_3, D_{\text{KL}}(q_{\Gamma_1}, q_{\Gamma_2}) > K_3$ : существуют значения гиперпараметров  $\boldsymbol{\lambda}_1, \boldsymbol{\lambda}_2$ , такие что  $Q(\mathbf{h}_1, \lambda_1) > Q(\mathbf{h}_2, \lambda_1), Q(\mathbf{h}_1, \lambda_1) < Q(\mathbf{h}_2, \lambda_2)$ .
6. Свойство непрерывности:  $\mathbf{h}^*, \boldsymbol{\theta}^*$  непрерывны по метопараметрам.

Первое свойство говорит о том, что решение первого и второго уровня должны быть согласованы и определены однозначно. Свойства 2-4 определяют возможные критерии оптимизации, которые должны приближаться обобщающей задачей. Свойство 5 говорит о возможности перехода между различными структурами модели. Отметим, что данное условие крайне важно в условиях оптимизации моделей глубокого обучения, которые отличаются многоэкстремальностью. Последнее свойство говорит о том, что обобщающая задача должна позволять производить переход между различными критериями выбора параметров и структуры модели непрерывно.

**Теорема 3.** Рассмотренные задачи не являются обобщающими.

*Доказательство.* TODO □

**Теорема 4.** Пусть задано непустое множество непрерывных по параметрам распределений на структуре  $\mathbf{P}$ . Пусть функции потерь и валидации  $L, Q$  являются непрерывно-дифференцируемыми на некоторой области  $U \subset \Theta \times \mathbb{H} \times \mathbb{A}$ , где параметры распределений  $\mathbf{P} \in \mathbb{A}$ . Тогда следующая задача является обобщающей на  $U$ .

$$\begin{aligned}
 \mathbf{h}^* &= \arg \max_{\mathbf{h}} Q = & (Q^*) \\
 &= \lambda_{\text{likelihood}}^Q \mathbb{E}_{q^*} \log p(\mathbf{y} | \mathbf{X}, \mathbf{w}, \boldsymbol{\Gamma}, \mathbf{h}, \lambda_{\text{temp}}, \mathbf{f}) - \\
 &\quad - \lambda_Q^{\text{prior}} D_{\text{KL}}(q^*(\mathbf{w}, \boldsymbol{\Gamma}) || p(\mathbf{w}, \boldsymbol{\Gamma} | \mathbf{h}, \lambda_{\text{temp}}, \mathbf{f})) - \\
 &\quad - \sum_{p' \in \mathbf{P}, \lambda \in \lambda_Q^{\text{struct}}} \lambda D_{\text{KL}}(\boldsymbol{\Gamma} | p') + \log p(\mathbf{h} | \mathbf{f}),
 \end{aligned}$$

где

$$\begin{aligned}
 q^* &= \arg \max_q L = \mathbb{E}_q \log p(\mathbf{y} | \mathbf{X}, \mathbf{w}, \boldsymbol{\Gamma}, \mathbf{h}, \lambda_{\text{temp}}, \mathbf{f}) & (L^*) \\
 &\quad - \lambda_L^{\text{prior}} D_{\text{KL}}(q^*(\mathbf{w}, \boldsymbol{\Gamma}) || p(\mathbf{w}, \boldsymbol{\Gamma} | \mathbf{h}, \lambda_{\text{temp}}, \mathbf{f})).
 \end{aligned}$$

*Доказательство.* TODO □

Метопараметрами данной задачи являются коэффициенты  $\lambda_Q^{\text{prior}}, \lambda_L^{\text{prior}}$ , отвечающие за регуляризацию верхней и нижней задачи оптимизации, коэффициент  $\lambda_{\text{likelihood}}^Q$  за максимизацию правдоподобия, а также параметры распределений  $\mathbf{P}$  и вектор коэффициентов перед ними  $\lambda_Q^{\text{struct}}$ .

В предельном случае, когда множество температура  $\lambda_{\text{temp}}$  близка к нулю, а множество  $\mathbf{P}$  состоит из распределений, близких к дискретным, и соответствующих всем возможным структурам, калибровка  $\lambda_Q^{\text{struct}}$  порождает последовательность задач оптимизаций, схожую с перебором структур.

TODO

Обобщающая задача: переформулировка через градиент

Обобщающая задача: адекватность задачи

Обобщающая задача: свойства коэффициентов

Решение задачи

Эксперимент: пример 1

Эксперимент: пример 2