

Теорема.

Пусть задана выборка \mathbf{X}, \mathbf{y} мощности m .

Пусть задана модель $\mathbf{f}(\mathbf{w}, \mathbf{X})$ и распределение q , аппроксимирующее апостериорное распределение параметров \mathbf{w} этой модели.

Рассмотрим выражение $\frac{1}{m} \text{ELBO}_\gamma$:

$$\frac{1}{m} \text{ELBO}_\gamma(\mathbf{X}, \mathbf{y}, q) = \frac{1}{m} \mathbb{E}_q \log p(\mathbf{y} | \mathbf{X}, \mathbf{w}) - \frac{\gamma}{m} \text{KL}(q | p(\mathbf{w})),$$

где $\gamma > 0$.

Пусть $\frac{1}{m} \text{ELBO}_\gamma$ сходится п.н. при $m \rightarrow \infty$ к функции $L(q)$ (вообще, она еще от гиперпараметров зависит, но здесь это будет лишним, прим. Олег).

Тогда функция $\frac{1}{m_0} \text{ELBO}_1$ для выборки мощности $m_0 = \frac{m}{\gamma}$ из той же генеральной совокупности сходится почти наверно к этой же функции $L(q)$:

$$\frac{1}{m_0} \text{ELBO}_1(\hat{\mathbf{X}}, \hat{\mathbf{y}}, q) \xrightarrow{\text{п.н.}} L(q),$$

где $|\hat{\mathbf{X}}| = m_0$.

Доказательство. Рассмотрим величину $\frac{1}{m} \text{ELBO}_\gamma$:

$$\frac{1}{m} \text{ELBO}_\gamma(\mathbf{X}, \mathbf{y}) = \frac{1}{m} \mathbb{E}_q \log p(\mathbf{y} | \mathbf{X}, \mathbf{w}) - \frac{\gamma}{m} \text{KL}(q | p(\mathbf{w})).$$

По УЗБЧ:

$$\frac{1}{m} \text{ELBO}_\gamma(\mathbf{X}, \mathbf{y}) \xrightarrow{m \rightarrow \infty} \mathbb{E}_{\mathbf{X}} \mathbb{E}_q \log p(\mathbf{y} | \mathbf{X}, \mathbf{w}) - \frac{\gamma}{m} \text{KL}(q | p(\mathbf{w})) = L(q).$$

Аналогично рассмотрим $\frac{1}{m_0} \text{ELBO}_1$ для выборки мощностью $m_0 = \frac{m}{\gamma}$:

$$\begin{aligned} \frac{1}{m_0} \text{ELBO}_1(\hat{\mathbf{X}}, \hat{\mathbf{y}}) &\xrightarrow{m \rightarrow \infty} \mathbb{E}_{\mathbf{X}} \mathbb{E}_q \log p(\mathbf{y} | \mathbf{X}, \mathbf{w}) - \frac{1}{m_0} \text{KL}(q | p(\mathbf{w})) = \\ &= \mathbb{E}_{\mathbf{X}} \mathbb{E}_q \log p(\mathbf{y} | \mathbf{X}, \mathbf{w}) - \frac{\gamma}{m} \text{KL}(q | p(\mathbf{w})) = L(q), \end{aligned}$$

предельные функции совпадают, что и требовалось доказать.

Интерпретация: для достаточно большого m и $\gamma > 0, \gamma \neq 1$ оптимизация параметров и гиперпараметров эквивалентна оптимизации ELBO для выборки другой мощности:

$$\begin{aligned} \max_q \text{ELBO}_\gamma(\mathbf{X}, \mathbf{y}, q) &\propto \max_q \frac{1}{m} \text{ELBO}_\gamma(\mathbf{X}, \mathbf{y}, q) \sim \max_q \frac{1}{m_0} \text{ELBO}_1(\hat{\mathbf{X}}, \hat{\mathbf{y}}, q) \sim \\ &\sim \max_q \text{ELBO}_1(\hat{\mathbf{X}}, \hat{\mathbf{y}}, q) \end{aligned}$$

К примеру, оптимизация ELBO_γ при $\gamma > 1$ эквивалентна оптимизации ELBO для выборки меньшей мощности (и большего вклада априорного распределения в оптимизацию).